

COMPUTACIÓN EVOLUTIVA Y ALGORITMOS GENÉTICOS: UN ANÁLISIS
TEÓRICO

DUALBER ANDRÉS MORELO OLIVARES
OSMEL DAVID ZUÑIGA CONTRERAS

POLITÉCNICO COLOMBIANO JAIME ISAZA CADAVID
FACULTA DE INGENIERÍA
APARTADÓ, ANTIOQUIA
2023

COMPUTACIÓN EVOLUTIVA Y ALGORITMOS GENÉTICOS: UN ANÁLISIS
TEÓRICO

DUALBER ANDRÉS MORELO OLIVARES
OSMEL DAVID ZUÑIGA CONTRERAS

TRABAJO DE INVESTIGACIÓN

PROFESOR
JORGE ERNESTO ESPINOSA OVIEDO

POLITÉCNICO COLOMBIANO JAIME ISAZA CADAVID
FACULTA DE INGENIERÍA
APARTADÓ, ANTIOQUIA
2023

CONTENIDO

	pág.
0.1 INTRODUCCIÓN	4
0.2 COMPUTACIÓN EVOLUTIVA Y ALGORITMOS GENÉTICOS: UN ANÁLISIS TEÓRICO	5
0.2.1 Definición y conceptos fundamentales	5
0.2.2 Orígenes y evolución de la computación evolutiva	5
0.3 FUNDAMENTOS DE LA COMPUTACIÓN EVOLUTIVA	6
0.3.1 Teoría de la evolución y su relación con la computación evolutiva	6
0.3.2 Representación de soluciones y codificación genética	6
0.3.3 Operadores evolutivos: selección, reproducción y mutación	7
0.4 ALGORITMOS GENÉTICOS	7
0.4.1 Concepto de algoritmos genéticos	7
0.4.2 Operadores de selección y métodos de codificación	7
0.4.3 Funciones de aptitud estándar	8
0.4.4 Variantes y mejoras de los algoritmos genéticos	8
0.4.5 Aplicaciones en inteligencia artificial y aprendizaje automático	9
0.5 USOS PRÁCTICOS	9
0.5.1 Algoritmos genéticos para el diseño de sistemas de MRI (Magnetic Resonance Imaging)	9
0.6 CONCLUSIONES	11

0.1 INTRODUCCIÓN

En el vasto mundo de la ciencia, el estudio de la evolución ha sido una cuestión apasionante y controvertida a lo largo de la historia. Desde los primeros intentos de comprender el origen y la diversidad de las especies, hasta los avances más recientes en el campo de la inteligencia artificial, la evolución ha sido una fuerza motriz que ha impulsado el desarrollo de numerosas disciplinas. fue Charles Darwin, en el siglo XIX, quien revolucionó nuestra comprensión de la evolución con su obra maestra "El origen de las especies". Darwin postuló que las especies cambian a lo largo del tiempo mediante un proceso llamado selección natural, en el cual los individuos mejor adaptados al entorno tienen mayores posibilidades de sobrevivir y reproducirse, transmitiendo sus características ventajosas a las siguientes generaciones. Las ideas de Darwin generaron un profundo impacto en la comunidad científica y en la sociedad en general. A medida que avanzaba el siglo XX, los científicos comenzaron a explorar cómo aplicar los principios de la evolución en campos como la computación y la optimización de problemas complejos. Surgió así un nuevo enfoque conocido como Computación Evolutiva, que se basa en simular los procesos evolutivos para resolver desafíos que resultan difíciles de abordar mediante métodos tradicionales.

Dentro de la Computación Evolutiva, los Algoritmos Genéticos se destacan como una técnica específica ampliamente utilizada. Los Algoritmos Genéticos se inspiran en la genética y la reproducción biológica, utilizando representaciones genéticas de soluciones y operadores evolutivos, como la selección, la reproducción y la mutación, para generar nuevas soluciones en cada generación. Estos algoritmos son especialmente útiles en problemas de optimización, donde se busca encontrar la mejor solución dentro de un amplio espacio de búsqueda.

En este tema exploraremos el fascinante mundo de la Computación Evolutiva y los Algoritmos Genéticos. Analizaremos cómo se han desarrollado a lo largo del tiempo, desde los primeros trabajos pioneros hasta las aplicaciones actuales en campos como la ingeniería, la inteligencia artificial y la biología computacional. También examinaremos los componentes fundamentales de los Algoritmos Genéticos, cómo se aplican en la resolución de problemas y qué ventajas ofrecen en comparación con otros métodos tradicionales, este tema nos sumergirá en la fascinante intersección entre la biología, la computación y la optimización, revelando cómo los principios de la evolución pueden ser aprovechados para abordar desafíos complejos en diversas áreas.

0.2 COMPUTACIÓN EVOLUTIVA Y ALGORITMOS GENÉTICOS: UN ANÁLISIS TEÓRICO

Introducción a la Computación Evolutiva y los Algoritmos Genéticos.

0.2.1 Definición y conceptos fundamentales

La Computación Evolutiva y los Algoritmos Genéticos son dos áreas fundamentales en el campo de la inteligencia artificial y la optimización. La Computación Evolutiva se basa en principios inspirados en la teoría de la evolución de Darwin, mientras que los Algoritmos Genéticos son una técnica específica dentro de esta disciplina.

Según [1], la Computación Evolutiva es un paradigma computacional que utiliza principios biológicos para resolver problemas complejos. Se basa en la idea de simular procesos evolutivos, como la selección natural, la reproducción y la mutación, para encontrar soluciones óptimas. La Computación Evolutiva es ampliamente utilizada en problemas de optimización y búsqueda, donde se busca encontrar la mejor solución posible en un espacio de búsqueda amplio y complejo.

Los Algoritmos Genéticos, introducidos por [2], son una técnica específica dentro de la Computación Evolutiva. Se basan en la evolución biológica y en la teoría de la genética mendeliana. En un Algoritmo Genético, las soluciones potenciales se representan como cadenas de bits llamadas cromosomas, donde cada bit corresponde a un gen. Estos cromosomas se combinan y mutan para generar nuevas soluciones, y luego se seleccionan las soluciones más aptas para la siguiente generación.

La selección de las soluciones más aptas se realiza mediante un proceso de evaluación y comparación de su rendimiento, utilizando una función de aptitud. Los Algoritmos Genéticos operan en poblaciones de soluciones y utilizan operadores como la selección de padres, la recombinación y la mutación para generar nuevas soluciones en cada generación.

0.2.2 Orígenes y evolución de la computación evolutiva

La computación evolutiva, como disciplina científica, tiene sus raíces en los estudios pioneros de John Holland en la década de 1960. [2] propuso la idea de utilizar conceptos de la teoría de la evolución biológica para resolver problemas complejos de optimización y búsqueda. Su trabajo seminal, "Adaptation in Natural and Artificial Systems", sentó las bases para el desarrollo de la computación evolutiva como un campo de investigación.

La influencia de los orígenes de la computación evolutiva puede rastrearse hasta los primeros trabajos de Alan Turing en la década de 1950, quien propuso el concepto de "máquinas universales" capaces de resolver una amplia gama de problemas. Estas ideas sentaron las bases teóricas para la computación evolutiva, al proporcionar un marco conceptual para la resolución de problemas mediante la simulación de procesos de selección y evolución.

A medida que avanzaba la década de 1970, investigadores como John Holland, Kenneth De Jong y David Goldberg ampliaron y refinaron los conceptos y técnicas de la computación evolutiva. Se realizaron avances significativos en la comprensión de la selección, los operadores genéticos y la representación de soluciones en forma de cromosomas. Con el tiempo, la computación evolutiva se ha convertido en un campo multidisciplinario, con contribuciones de la biología, la informática, la matemática y la ingeniería.

0.3 FUNDAMENTOS DE LA COMPUTACIÓN EVOLUTIVA

0.3.1 Teoría de la evolución y su relación con la computación evolutiva

La teoría de la evolución de Darwin ha sido una influencia central en el desarrollo de la computación evolutiva como campo de estudio. La relación entre la teoría de la evolución y la computación evolutiva radica en la aplicación de los principios evolutivos biológicos a los sistemas computacionales.

La teoría de la evolución, presentada por Charles Darwin en su obra "El origen de las especies" en 1859, postula que las especies evolucionan a lo largo del tiempo mediante la selección natural y la supervivencia de los más aptos. Este proceso implica la reproducción diferencial de los individuos en una población, donde aquellos con características favorables tienen una mayor probabilidad de transmitir sus genes a la siguiente generación. La computación evolutiva se inspira en estos principios para resolver problemas complejos mediante la simulación de procesos evolutivos. Los individuos en un sistema computacional representan soluciones potenciales, y a través de operadores como la selección, la reproducción y la mutación, se generan nuevas soluciones en cada generación. Estas soluciones son evaluadas mediante una función de aptitud que determina su calidad y se aplican mecanismos de selección para favorecer la propagación de las soluciones más aptas.

La relación entre la teoría de la evolución y la computación evolutiva ha sido ampliamente estudiada y desarrollada por investigadores en el campo, ya que proporciona una manera efectiva de explorar espacios de búsqueda complejos además de encontrar soluciones óptimas, aprovechando la eficacia de los procesos evolutivos que han sido refinados a lo largo de millones de años de evolución biológica.

0.3.2 Representación de soluciones y codificación genética

En la computación evolutiva y los algoritmos genéticos, la representación de soluciones y la codificación genética desempeñan un papel crucial en el proceso de búsqueda y optimización. La forma en que se representan las soluciones y se codifican los genes determina la estructura y el espacio de búsqueda que se explorará. La representación de soluciones puede variar según el problema y el dominio específico. Una representación comúnmente utilizada es la representación binaria, donde las soluciones se codifican como cadenas de bits. Cada bit puede corresponder a un gen específico que representa una característica o valor de la solución. Esta representación permite una fácil manipulación y aplicación de operadores genéticos como la recombinación y la mutación [6].

Otra forma de representación ampliamente utilizada es la representación real o numérica, donde los genes se codifican como valores reales en un rango determinado. Esta representación es especialmente útil en problemas donde las soluciones son valores continuos, como la optimización de parámetros en algoritmos de aprendizaje automático [5]. La elección adecuada de la representación de soluciones y la codificación genética es esencial para el éxito de la computación evolutiva y los algoritmos genéticos, dado una representación inadecuada puede dificultar la exploración eficiente del espacio de búsqueda o llevar a soluciones no tan favorables.

Además de las representaciones binarias y reales, existen otras formas de representación más complejas, como las estructuras de árbol utilizadas en la programación genética. Estas representaciones permiten la expresión de soluciones en forma de programas o estructuras jerárquicas, lo que amplía la capacidad de abordar problemas más complejos [7].

0.3.3 Operadores evolutivos: selección, reproducción y mutación

Los operadores evolutivos, que incluyen la selección, la reproducción y la mutación, son fundamentales en la computación evolutiva y los algoritmos genéticos. Estos operadores imitan los procesos de selección natural y evolución biológica, permitiendo la generación de nuevas soluciones y la mejora gradual de la población.

La selección: es el proceso mediante el cual se eligen individuos para formar parte de la siguiente generación, basándose en su aptitud o calidad. Se utilizan diferentes métodos de selección, como la selección por torneo o la selección proporcional a la aptitud, para asegurar la supervivencia de los individuos más aptos y promover la diversidad genética.

La reproducción: consiste en la creación de nuevos individuos a partir de la combinación de los genes de dos padres seleccionados. Esto se logra mediante operadores como la recombinación o cruzamiento, que intercambian partes de los cromosomas de los padres para generar descendencia con características mixtas.

La mutación: es un proceso que introduce cambios aleatorios en los genes de un individuo. Estos cambios pueden ser pequeños, como la modificación de un solo bit en la representación binaria, o más complejos, como la inserción o eliminación de genes. La mutación permite la exploración de nuevas regiones del espacio de búsqueda y evita la estancación en óptimos locales.

Estos operadores evolutivos trabajan en conjunto para mejorar la población de soluciones en cada generación, permitiendo la búsqueda y optimización de problemas complejos. La selección favorece la supervivencia de los más aptos, la reproducción combina características genéticas beneficiosas y la mutación introduce variabilidad. Esta combinación de operadores evolutivos es esencial para el éxito de la computación evolutiva y los algoritmos genéticos.

0.4 ALGORITMOS GENÉTICOS

0.4.1 Concepto de algoritmos genéticos

Un algoritmo genético es una técnica de búsqueda interactiva inspirada en los principios de selección natural, no busca modelar la evolución biológica sino derivar estrategias de optimización. El concepto se basa en la generación de poblaciones de individuos mediante la reproducción de los padres con esto se pretendió dar solución a muchos problemas que tienen funciones objetivos complejos dado que la optimización tiende a finalizar en mínimos y máximos locales, la idea de los algoritmos genéticos es optimizar una función objetivo utilizando los principios de la selección natural sobre los parámetros de la función [8].

0.4.2 Operadores de selección y métodos de codificación

Los operadores de selección y los métodos de codificación son componentes esenciales en los algoritmos genéticos. La selección determina qué individuos se reproducen y cuáles se descartan, influyendo en la evolución de la población. Diferentes métodos de selección, como la selección por torneo o la selección proporcional a la aptitud, ofrecen enfoques distintos para equilibrar la exploración y la explotación. Por otro lado, los métodos de codificación definen cómo se representan las soluciones y cómo se aplican los operadores genéticos. La elección de una codificación adecuada tiene un impacto significativo en la eficiencia y efectividad del algoritmo genético.

En cuanto a la selección, el método del torneo, propuesto por Miller en 1995, elige aleatoriamente un subconjunto de individuos de la población y selecciona el mejor de ellos para la reproducción. Por otro lado, la selección proporcional a la aptitud, también conocida como selección por ruleta, asigna una probabilidad de selección a cada individuo de la población basándose en su aptitud relativa. En cuanto a la codificación, existen diferentes métodos según el tipo de problema. La codificación binaria es ampliamente utilizada y representa las soluciones como cadenas de bits. La codificación real o numérica se utiliza cuando las soluciones son valores continuos. Además, existen métodos de codificación específicos para problemas particulares, como la codificación de árboles en la programación genética.

La elección adecuada de los operadores de selección y los métodos de codificación es crucial para el desempeño de los algoritmos genéticos y la resolución eficiente de los problemas para llegar a soluciones óptimas que así lo requieran.

0.4.3 Funciones de aptitud estándar

Las funciones de aptitud son una parte fundamental, ya que permiten evaluar y comparar la calidad de las soluciones en cada generación. Estas funciones asignan un valor numérico a cada individuo de la población en función de su rendimiento o adecuación para resolver el problema en cuestión. Existen diferentes tipos de funciones de aptitud estándar que se utilizan comúnmente en los algoritmos genéticos. Por ejemplo, en problemas de maximización, la función de aptitud puede ser simplemente el valor objetivo que se busca maximizar. En problemas de minimización, la función de aptitud puede ser el inverso del valor objetivo o alguna otra métrica inversa.

Además, se pueden emplear funciones de aptitud más complejas y adaptativas. Por ejemplo, se pueden utilizar funciones de aptitud basadas en rangos, donde se asigna una puntuación relativa a cada individuo en función de su posición en la población.

Es importante seleccionar una función de aptitud adecuada que refleje las características y objetivos del problema específico. Una función de aptitud bien diseñada permitirá una selección efectiva de los individuos más aptos y promoverá la convergencia hacia soluciones óptimas.

0.4.4 Variantes y mejoras de los algoritmos genéticos

Los algoritmos genéticos han evolucionado a lo largo del tiempo, y se han desarrollado diversas variantes y mejoras para abordar distintos desafíos en la optimización y búsqueda de soluciones. Estas variantes y mejoras se han convertido en áreas de investigación activas en la computación evolutiva.

Una de las variantes más conocidas es el algoritmo genético de edad, propuesto por Holland en 1992, que introduce un envejecimiento programado en la población. Este enfoque busca preservar la diversidad genética y evitar la convergencia prematura hacia soluciones no requeridas. Otra variante común es el algoritmo genético de islas, donde se dividen la población en subpoblaciones o islas que evolucionan de forma independiente. Periódicamente, los individuos migran entre islas, permitiendo el intercambio de información genética y promoviendo la exploración global del espacio de búsqueda.

Además de las variantes, se han propuesto mejoras en los operadores genéticos. Por ejemplo, los operadores de recombinación basados en el concepto de búsqueda en vecindario han demostrado su eficacia en problemas de optimización combinatoria. También se han desarrollado métodos de adaptación de parámetros para ajustar dinámicamente los operadores genéticos durante la ejecución del algoritmo. Estas variantes y mejoras demuestran la flexibilidad y capacidad de adaptación de

los algoritmos genéticos, permitiendo abordar una amplia gama de problemas de optimización. Su continuo desarrollo y aplicación en diversas áreas de investigación subrayan su relevancia y potencial en la actualidad.

0.4.5 Aplicaciones en inteligencia artificial y aprendizaje automático

han encontrado aplicaciones significativas en el campo de la inteligencia artificial y el aprendizaje automático. Estas técnicas se utilizan para abordar problemas complejos de optimización y búsqueda en diversos dominios. En el campo de la inteligencia artificial, los algoritmos genéticos se han aplicado en el diseño de redes neuronales y la optimización de sus parámetros. Mediante la evolución de la estructura y los pesos de la red, los algoritmos genéticos han demostrado su eficacia en la mejora del rendimiento y la capacidad de generalización de las redes neuronales.

En el aprendizaje automático, los algoritmos genéticos se utilizan en la selección de características, donde se busca encontrar el subconjunto óptimo de características más relevantes para un problema dado. Esto permite reducir la gran dimensión de los datos y mejorar la precisión y eficiencia de los modelos de aprendizaje automático. Además, los algoritmos genéticos se aplican en la optimización de parámetros de algoritmos de aprendizaje automático, como los clasificadores o los modelos de regresión. Al combinar la exploración global del espacio de búsqueda de los algoritmos genéticos con las técnicas de aprendizaje automático, se logra una optimización más eficiente y efectiva.

0.5 USOS PRÁCTICOS

0.5.1 Algoritmos genéticos para el diseño de sistemas de MRI (Magnetic Resonance Imaging)

Se presenta un software llamado CamGASP, diseñado para el desarrollo de equipos médicos de resonancia magnética (MRI), utilizando algoritmos genéticos (AG). Estos algoritmos permiten que una población de diseños evolucione hacia la mejor opción. El objetivo principal es optimizar la función de costo, buscando maximizar la homogeneidad de la imagen de interés en el MRI, considerando factores ingenieriles como el ancho, volumen y esfuerzos de las espirales electromagnéticas (coils), así como la intensidad del campo magnético, de acuerdo con las especificaciones de cada comprador. En este caso, cada "gen" del código representa una espiral magnética, que se combinará y mutará de manera conveniente para lograr la mejor resolución de imágenes en el MRI. Este enfoque no se limita solo a MRI de cuerpo completo, sino que también permite construir equipos más pequeños para el procesamiento de imágenes de partes específicas del cuerpo o incluso obtener tomografías PET (tomografías por emisión de positrones).

Una ventaja destacada de este software es que puede ejecutarse en paralelo en varias unidades que comparten información sobre las mutaciones de los "genes" de información, lo que acelera el proceso de evolución del diseño. La siguiente imagen ilustra cómo estos algoritmos se vuelven cada vez más óptimos y eficientes a medida que evolucionan.




Figure 1. Tasa de aptitud

La evolución de la función aptitud con un número de generaciones. Se puede apreciar que la función aptitud mejora rápidamente al inicio de la optimización. Después, las curvas se aplanan hacia fuera mientras que otras mejoras en el diseño llegan a ser difíciles. Una vez que un nicho permanece inmóvil por más de 2000 generaciones, el nicho es reinicializado.

¿Por qué utilizar algoritmos genéticos? El diseño de los equipos de resonancia magnética (MRI) se adapta a las necesidades de los compradores y sus especialidades, lo que implica que las variables de diseño varíen para cada caso. En este sentido, el uso de una solución basada en lógica difusa no sería eficiente, ya que llevaría más tiempo desarrollar una relación entre las espirales magnéticas y la función de costo, y estas relaciones serían diferentes para cada usuario. Por otro lado, también se podría considerar el uso de redes neuronales, pero sería necesario comparar el tiempo necesario para alcanzar una solución óptima en comparación con los algoritmos genéticos.

0.6 CONCLUSIONES

La Computación Evolutiva y los Algoritmos Genéticos son fundamentales en el campo de la inteligencia artificial y la optimización, esta basa en principios biológicos para resolver problemas complejos, simulando procesos evolutivos como la selección natural, la reproducción y la mutación. La teoría de la evolución de Darwin ha sido una influencia central en el desarrollo de la computación evolutiva. Con esto los operadores evolutivos, como la selección, la reproducción y la mutación, son esenciales para determinar los procesos a los que tiene fin los algoritmos genéticos, La selección elige individuos para formar parte de la siguiente generación, la reproducción combina genes de los padres y la mutación introduce cambios aleatorios. Estos operadores trabajan en conjunto para mejorar la población de soluciones en cada generación. Los operadores de selección y los métodos de codificación son componentes esenciales. Las funciones de aptitud son fundamentales en los algoritmos genéticos, ya que evalúan y comparan la calidad de las soluciones. Pueden ser simples, basadas en el valor objetivo, o más complejas y adaptativas, como las funciones de aptitud basadas en rangos. para su éxito en la resolución de problemas específicos. Con todo esto se pretende comprender que la computación evolutiva y los algoritmos genéticos desde su origen funcionan como base de optimización para resolver problemas del mundo actual desde la perspectiva de la evolución.

La Computación Evolutiva y los Algoritmos Genéticos han demostrado ser herramientas efectivas en el campo de la inteligencia artificial y la optimización. Han evolucionado a lo largo de los años, gracias a los avances en la comprensión de los principios de la evolución y la genética, así como a la mejora de los métodos y técnicas utilizadas. Estas disciplinas han contribuido significativamente al desarrollo de soluciones para problemas complejos de optimización y búsqueda en diversos campos.

Las perspectivas futuras para la computación evolutiva y los algoritmos genéticos son prometedoras. A medida que la tecnología continúa avanzando, se espera que estas disciplinas sean aplicadas en una variedad de campos, como la medicina, la ingeniería, la robótica y la inteligencia artificial. Además, se espera que se desarrollen variantes y mejoras de los algoritmos genéticos para abordar desafíos específicos y mejorar su eficiencia y efectividad.

Se espera que la investigación en computación evolutiva y algoritmos genéticos se enfoque en áreas como el diseño automatizado, la optimización de sistemas complejos, la resolución de problemas combinatorios, Se espera que se desarrollen nuevos métodos y técnicas, así como una mejor comprensión de los procesos evolutivos, lo que permitirá abordar problemas aún más desafiantes. problemas complejos de optimización y búsqueda. Las perspectivas futuras son prometedoras, con aplicaciones en diversos campos y el desarrollo de variantes y mejoras de los algoritmos genéticos. La investigación continua en estas áreas abrirá nuevas posibilidades y permitirá abordar desafíos aún más difíciles en el futuro.

REFERENCIAS

- [1] Back, T., Fogel, D. B., & Michalewicz, Z. (1997). Handbook of evolutionary computation. Oxford University Press. Universidad Libre.
- [2] Holland, J. H. (1975). Adaptation in natural and artificial systems. University of Michigan Press.
- [3] Engelbrecht, A. P. (2007). Computational intelligence: An introduction. John Wiley & Sons.
- [4] Sivanandam, S. N., & Deepa, S. N. (2008). Introduction to genetic algorithms. Springer.
- [5] Deb, K. (2001). Multi-objective optimization using evolutionary algorithms. John Wiley & Sons.
- [6] Goldberg, D. E. (1989). Genetic algorithms in search, optimization, and machine learning. Addison-Wesley.
- [7] Koza, J. R., Poli, R., & Banzhaf, W. (2003). Human-competitive results produced by genetic programming. Genetic Programming and Evolvable Machines, 4(3), 241-259.
- [8] Cruz, P. P. (2010). Inteligencia Artificial con aplicaciones a la ingeniería . Mexico: Alfaomega.